Bias – Variance Practice

Optimization and Statistical Inference Lab

김낙일 석사과정

1.개발환경 설정

2. Jupyter Notebook

3. Polynomial Regression

4. Bias and Variance Analysis

MobaXterm 접속


```
ssh -X -p 2222 com**02@143.248.159.**
source ~/.bashrc
```

Shell V

- PC 앞에 적혀진 IP 주소 접속
- 대문자 X 주의!

■ 개발환경 설정

- 1. Terminal 창에 code : 입력! (영어 code 치고 뛰어쓰기 두번) * 실행 안될 시에 killall code 입력 후 실행
- 2. 실행된 visual studio code에서 왼쪽 위 File 탭 -> Open Folder -> Samsung_ds_tutorial 폴더로 이동 후 왼쪽 아래 OK 클릭
- 3. Bias-Variance-practice_KOR(Student).ipynb 실행 + 환경 바꿔주기 (그림 참고)
- 4. 패키지 import 되는 지 확인 (shift+enter)



```
# Loading Packages
import random
import numpy as np
import matplotlib.pyplot as plt
from collections import defaultdict
from sklearn.preprocessing import PolynomialFeatures
from sklearn.li
hear_model import LinearRegression
from sklearn.pipeline import Pipeline
from sklearn.metrics import mean_squared_error
```

가상환경 변경

패키지 import

Git Clone, 가상환경 설치 (설치가 안되어 있을 경우)

```
git clone https://github.com/forestnoobie/samsung_ds_tutorial.git
cd samsung_ds_tutorial
conda env create --file samsung_bias.yml
conda activate samsung_bias
python -m ipykernel install --user --name=samsung_bias
jupyter notebook --port 9999
```

Shell v


■ 개발환경 설정

Jupyter 및 Firefox 오류

```
## Fire Fox 켜져 있을 경우
pidof firefox
# 켜져있으면 Process ID (PID)가 나옴
kill -9 [PID]
## jupyter server가 켜져있을 경우
jupyter notebook list
jupyter notebook stop [PORT]
# ex) 8888 사용 중이면 jupyter notebook stop 8888
# 위 명령어로 대처가 안 될 시
lsof -i tcp:[PORT]
kill -9 [PID]
                                                                  Shell V
```

■ 개발환경 설정

Jupyter notebook kernel 바꿔주기 (samsung_bias)



Jupyter notebook Import

```
import random
import numpy as np
import matplotlib.pyplot as plt
from collections import defaultdict
from sklearn.preprocessing import PolynomialFeatures
from sklearn.linear_model import LinearRegression
from sklearn.pipeline import Pipeline
from sklearn.metrics import mean_squared_error
```

Jupyter Notebook 이란?

- 오픈소스 웹 어플리케이션
- 파이썬 코드 실행, 텍스트 작성 가능
- Cell 들로 구성

Bias Variance Analysis

- In this notebook
- 1. We will practice to compute bias and variance in polynomial regression
- 2. Understand the trade off relation between bias and variance

```
[55]: # Loading Packages
import random
import numpy as np
import matplotlib.pyplot as plt
from collections import defaultdict
from sklearn.preprocessing import PolynomialFeatures
from sklearn.linear_model import LinearRegression
from sklearn.pipeline import Pipeline
from sklearn.metrics import mean_squared_error
```

Jupyter Notebook ਾਜੋ

• 2가지 Mode 존재

```
In [ ]:
```

Command Mode

- 진입 방법 : [Esc]
- Cell 실행 : Ctrl + [Enter]
- Cell 합치기 : Shift + m
- Cell 추가하기 : b
- 변수 초기화 : 00

```
In [ ]: [
```

Edit Mode

- 진입 방법 : [Enter]
- 코드 작성

Jupyter Notebook ਾਂਗ

- 변수 안에 값을 바로 출력해볼 수 있다!
- 실습 중간에 변수의 값을 확인하고 싶으면 아래와 같이 출력을 권장


```
In [3]: a = 3+5
b = 2*a +10
c = a+ 2*b
In [4]: c
Out [4]: 60
```

Jupyter Notebook 정리

1. b : 셀 추가!

2. Ctrl + Enter : 실행!

실습 목표: Polynomial Regression 을 Sin 함수 근사, Bias/Variance 비교



패키지 불러오기

```
[55]: # Loading Packages
import random
import numpy as np
import matplotlib.pyplot as plt
from collections import defaultdict
from sklearn.preprocessing import PolynomialFeatures
from sklearn.linear_model import LinearRegression
from sklearn.pipeline import Pipeline
from sklearn.metrics import mean_squared_error
```

Random: 난수 생성에 관한 패키지

Numpy: 행렬을 다루기 위한 패키지


Matplotlib: 그래프 그리기 위한 시각화 패키지

Collections : 자료형에 관한 패키지

Sklearn: 머신러닝 모델 패키지

Polynomial Regression 예시 만들기

- 1. np.arange [0, 4] 까지 고르게 분할 (정수)
- 2. $y = 3 2x + x^2 x^3$ 만들기
- 3. 그래프로 그리기



Polynomial Regression 예시 만들기 (실습)

- 1. 정의역 x_temp : 범위가 [0,1,2,3,4,5,6,7,8] 까지의 행렬을 만들기
- 2. 치역 y_temp = 10 * X_temp**3 + 7 * X_temp -10 만들기
- 3. Ploting 해보기

Polynomial Regression 예시 만들기

- 1. Degree 2 polynomial feature 생성
- 2. $(x) \rightarrow (1, x, x^2)$
- 3. 해당 차수에 맞게 feature 생성

```
poly = PolynomialFeatures(degree=2)
X ex trans = poly.fit transform(X ex[:, np.newaxis])
print("Output of Polynomial Features")
print(X ex trans)
for row in range(X_ex_trans.shape[0]):
                                             ".format(X_ex_trans[row,0],X_ex_trans[row,1")
Output of Polynomial Features
[[ 1. 0. 0.]
 [ 1. 1. 1.]
 [1. 2. 4.]
[ 1. 3. 9.]
 [ 1. 4. 16.]]
constant : 1.0, x1 : 0.0, x1**2 : 0.0
constant : 1.0, x1 : 1.0, x1**2 : 1.0
constant : 1.0, x1 : 2.0, x1**2 : 4.0
constant: 1.0, x1: 3.0, x1**2: 9.0
constant: 1.0, x1: 4.0, x1**2: 16.0
```

Polynomial Regression 예시 만들기 (실습)

```
poly_practice = PolynomialFeatures(degree=?)
X_ex_trans = poly_practice.fit_transform(X_ex[:, ??])

print("Input")
print(X_ex)
print("Output of Polynomial Features")
print(X_ex_trans)
for row in range(??):
    print("constant : {}, x1 : {}, x1**2 : {}, x1**3 : {}".format(X_ex_trans[row,0],X_ex_trans[row,1], X_ex_trans[row,2], X_ex_trans[row,3] ))
```

- 1. degree = 3 인 Polynomial Feature 를 poly_practice로 선언해보세요
- 2. input X_ex를 1에서 선언한 poly_practice를 이용하여 변환해 보세요
- 3. 변환 결과를 출력해보세요

Polynomial Regression 예시 만들기

- 1. Pipeline : 함수들을 엮어서 하나의 함수로 변환
- 2. model.fit(x, y)x,y 데이터를 이용하여 학습
- 3. model.named_steps['linear'].coef_ Linear 모델의 계수 불러오기
- 4. model.predict(x) X를 model 에 투입하여 output 구하기

Polynomial Regression 예시 만들기 (실습)

- 1. degree = 3 인 Polynomial Regression 를 model_practice로 선언해보세요
- 2. X_ex, Y_ex input으로 model_practice을 학습해보세요
- 3. model_practice 의 계수를 출력해보세요 (상수포함 4개)
- 4. Ground Truth와 Predicted 값을 그래프를 그려보세요

■ Polynomial Regression 이용하여 Sine 함수 예측

Polynomial 모델을 이용하여 다항 함수가 아닌 sine 함수를 근사해보도록 합시다

- 1. Synthetic 데이터를 생성
- 2. Synthetic 데이터에 noise를 일부 추가, Train/Test set으로 분리
- 3. Train set을 이용하여 모델을 학습하고 Test set을 이용하여 모델의 성능을 평가
- 4. Regression 성능 지표인 Mean Squared loss와 Bias/Variance를 측정해봅니다

데이터셋 만드는 함수 정의

- get_y_true(x)
 X에 대한 sin(x) 값 구하기
- 2. get_y_noise(x) X에 대한 noise + sin(x) 값 구하기
- 3. get_sample(sample_ratio, x,y) X, y 에서 ratio 만큼 sample 추출

```
np.random.seed(10)
random.seed(10)
def get_y_true(x):
   y = np.sin(x)
   return y
def get y noise(x):
   y = get_y_true(x) + np.random.uniform(-0.4, 0.4, len(x))
   return y
def get sample(sample ratio, x, y):
   m = len(x)
    m_new = int(np.round(sample_ratio*m))
    ind = random.sample(range(m), m_new)
    ind = np.sort(ind)
    x_sample = x[ind]
   y_sample = y[ind]
   y_true_sample = get_y_true(x_sample)
    return x sample, y sample, y true sample
```

Dataset 분할하기

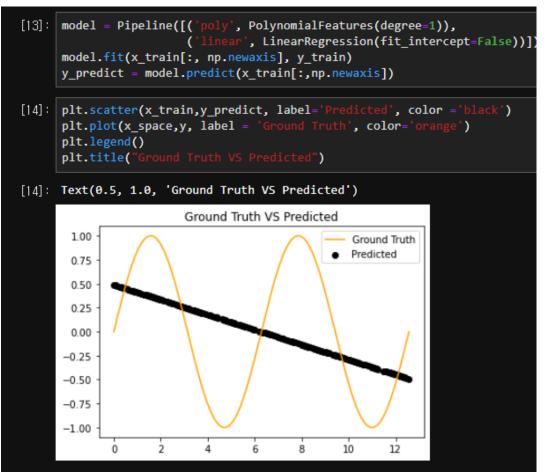
```
np.random.seed(10)
    rand_indicies = list(range(0,x_num))
    random.shuffle(rand_indicies)
    rand_idicies_train, rand_idicies_test |=rand_indicies[:int(x_num*0.8)], rand_indicies[int(x_num*0.8):]
    x_train = x_space[rand_idicies_train]
    y_train = get_y_noise(x_train)

    x_test = x_space[rand_idicies_test]
    y_test = get_y_noise(x_test)
```

• 전체 데이터를 학습 데이터 x_train ,y_train 과 Test 데이터 x_test, y_test로 나누기

Polynomial regression (degree =1) 만들기

- 1. degree 1 인 model 생성
- 2. X_train 이용하여 학습
- 3. 학습 결과 시각화



Mean Square Error 계산

- result_dict
 결과 저장을 위한 dictionary
- 2. Mean_square_error 계산

$$MSE = \frac{1}{n} \sum (y - \hat{y})^2$$
 (실제값과 예측값 차이)

```
[15]: # Dictionary for containing the results
    result_dict = defaultdict(dict)

Checking Mean Square Error

[16]: y_test_predict = model.predict(x_test[:,np.newaxis])
    ## check Train, Test mse
    mse_train = mean_squared_error(y_train,y_predict)
    mse_test = mean_squared_error(y_test,y_test_predict)
    result_dict[1]['mse_train'] = mse_train
    result_dict[1]['mse_test'] = mse_test
    print("mse_Train : {}, Test : {}".format(mse_train,mse_test))

mse_Train : 0.456555897331168, Test : 0.4686182390294486
```

Polynomial Regression 이용하여 Sine 함수 예측

Bias and Variance

$$bias = \mathbb{E}[f'(x)] - f(x)$$

• 예측값의 평균과 실제값의 차이

$$variance = \mathbb{E}\Big[\big(f'(x) - \mathbb{E}[f'(x)]\big)^2\Big]$$

• 예측값의 분산

$$\mathbb{E}[f'(x)] = \frac{1}{n} \sum_{i=0}^{n-1} f'_i(x)$$

Bias 구하기

```
random.seed(10)
num sampling = 1000
degree = 1
model list = []
exp f x = np.zeros(len(x train))
for i in range(num sampling):
    x train sample, y train sample, y train true = get sample(sample ratio=0.3,x=x train,y=y train)
    model = Pipeline([('poly', PolynomialFeatures(degree=degree)),
                  ('linear', LinearRegression(fit_intercept=False))])
    model.fit(x_train_sample[:, np.newaxis], y_train_sample)
    exp_f_x += model.predict(x_train[:, np.newaxis])
    model list.append(model)
exp_f_x/=num_sampling
bias = (np.linalg.norm(exp_f_x-y_train))
print("Exp_f_X",np.mean(exp_f_x))
```

- num_sampling 만큼 sample 추출 (Dataset 만들기)
- E[f'(x)] 구하기 (exp_f_x)
- Bias 계산

Variance 구하기

```
var = 0
for j in range(num_sampling):
    model = model_list.pop(0)
    var = var + np.square(model.predict(x_train[:, np.newaxis])-exp_f_x)
var = var/num_sampling
variance = np.linalg.norm(var)

result_dict[1]['bias'] = bias
result_dict[1]['var'] = variance
print("degree : {} bias : {} variance : {}".format(degree, bias,variance) )
```


• f'(x) 분산 계산

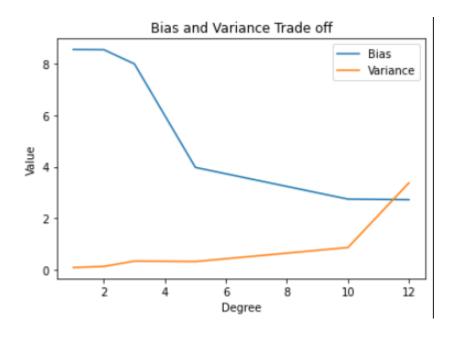
Polynomial Regression 이용하여 Sine 함수 예측

Degree = 5 Practice

- Degree 5 일 때 직접 실습해보기
- Train MSE, Test MSE 계산
- Bias, Variance 계산

Degree 에 따른 bias , variance 비교



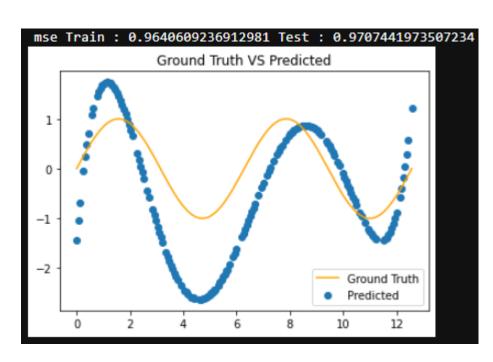


강한 노이즈 데이터 생성

Random.uniform(-20,-1)
 -20에서 -1 사이의 숫자 추출 (노이즈 생성)


```
random.seed(10)
x_noise = [random.uniform(4,6) for i in range(10)]
y_noise = [random.uniform(-20,-1) for i in range(10)]
plt.scatter(x_train,y_train, label='Train data')
plt.scatter(x_noise,y_noise, label='Noise data')
plt.legend()
plt.title("Train Data with noise")
Text(0.5, 1.0, 'Train Data with noise')
                     Train Data with noise
 -2.5
 -5.0
 -7.5
-10.0
-12.5
-15.0
           Train data
-17.5
           Noise data
-20.0
                                           10
                                                  12
```

강한 노이즈 데이터 생성



Degree = 5

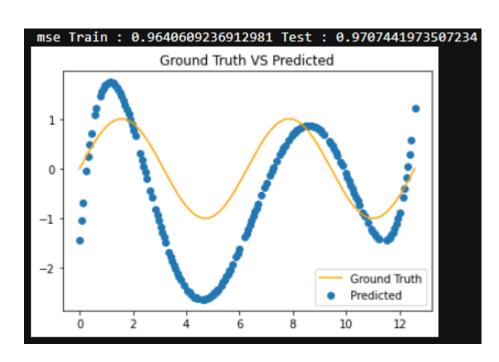
 $MSE_Test = 0.970$



Degree = 10


 $MSE_Test = 1.207$

강한 노이즈 데이터 생성



Degree = 5

 $MSE_Test = 0.970$



Degree = 10

 $MSE_Test = 1.207$

